Análisis de Clustering con K-Means y DBSCAN sobre el Top 50 de Spotify

Ilian Joseph Felipez Vaca
Diplomado en Big Data, Analytics y Business Intelligence V1
Universidad Privada del Valle (Univalle)
Bolivia
ilian.felipezvaca@postgrado.univalle.edu

Miguel Angel Mollericona Cuentas
Diplomado en Big Data, Analytics y Business Intelligence V1
Universidad Privada del Valle (Univalle)
Bolivia
miguel.mollericonacuentas@postgrado.univalle.edu

Marcelo Favio Nina Calsina
Diplomado en Big Data, Analytics y Business Intelligence V1
Universidad Privada del Valle (Univalle)
Bolivia
marcelo.ninacalsina@postgrado.univalle.edu

Paola Melani Quispe Mamani
Diplomado en Big Data, Analytics y Business Intelligence V1
Universidad Privada del Valle (Univalle)
Bolivia
paola.quispemamani@postgrado.univalle.edu

Eugenia Tintaya Maquera
Diplomado en Big Data, Analytics y Business Intelligence V1
Universidad Privada del Valle (Univalle)
Bolivia
eugenia.tintayamaquera@postgrado.univalle.edu

***Resumen*—Este artículo presenta un análisis de clustering no supervisado sobre el conjunto de datos *Top Spotify Songs in 73 Countries (Daily Updated)*, con el objetivo de caracterizar los perfiles acústicos predominantes en el Top 50 mundial de Spotify. Se seleccionaron once variables acústicas (danceability, energy, valence, acousticness, instrumentalness, liveness, speechiness, tempo, loudness, duration_ms y mode) a partir de un dataset de 2.1 millones de registros. Tras un proceso de limpieza, transformación logarítmica y estandarización, se tomó una muestra aleatoria de 100.000 canciones. Se implementaron y compararon dos algoritmos de clustering: K-Means y DBSCAN. Los resultados muestran que K-Means identifica 2 grandes perfiles musicales (bailable-energético-positivo y mixto-equilibrado), mientras que DBSCAN detecta 8 clusters más específicos, incluyendo perfiles como *popular comercial*, *instrumental introspectivo*, *folk alegre* y *balada lenta*, además de identificar 12 puntos atípicos. DBSCAN obtuvo un coeficiente de Silhouette de 0.516, superior al de K-Means (0.210), indicando una mejor separación entre clusters. Se concluye que la música popular mundial presenta al menos dos grandes perfiles dominantes con múltiples subperfiles de nicho, y que la elección del algoritmo de clustering depende del objetivo del análisis: K-Means para segmentación general rápida, DBSCAN para detección de grupos pequeños y datos atípicos.**

***Index Terms*—Clustering no supervisado, K-Means, DBSCAN, música digital, Spotify, características acústicas, análisis de datos musicales.**

I. Introducción

I-A. Problema que abordamos

En la industria del streaming musical, plataformas como Spotify generan diariamente millones de datos sobre las preferencias de los oyentes. Sin embargo, para una discográfica o un artista independiente, la pregunta clave no es únicamente qué canción es popular, sino qué perfiles musicales tienden a repetirse entre los grandes éxitos. ¿Predominan las canciones con alta capacidad de baile sobre las baladas de baja energía? ¿Las canciones con contenido explícito conforman un grupo propio? ¿Existe una combinación de características acústicas que distinga a las canciones del Top 50?

El presente proyecto busca responder estas interrogantes mediante técnicas de clustering no supervisado (k-means y DBSCAN), con el objetivo de **caracterizar y tipificar los perfiles acústicos predominantes en el Top 50 mundial**. Los resultados obtenidos no tienen capacidad predictiva sobre el éxito futuro, pero permiten una **descripción empírica y cuantitativa de los patrones acústicos presentes en canciones exitosas**. Dicha caracterización constituye un punto de partida para estudios posteriores orientados a la producción y el análisis de tendencias musicales.

I-B. Preguntas de investigación

1. ¿Cuántos grupos naturales de canciones existen en el Top 50 mundial de Spotify?
2. ¿Es posible asignar nombres descriptivos a los *clusters* basándose en sus valores promedio de `danceability`, `energy` y `valence`?
3. ¿Qué combinación de valores caracteriza a cada perfil musical?
4. ¿Cuál de los dos algoritmos de clustering evaluados (*k-means* vs *DBSCAN*) produce una mejor separación de los datos, medida mediante el coeficiente de *Silhouette*?

I-C. *Pertinencia e interés para el curso*

El proyecto documenta todas las fases del ciclo de vida de un proyecto de datos, incluyendo adquisición, preprocesamiento, modelado y evaluación. Los resultados obtenidos permiten describir objetivamente los perfiles acústicos de las canciones exitosas, demostrando la utilidad del análisis de datos en un sector concreto. Adicionalmente, la comparación entre k-means y DBSCAN aporta criterios para la selección de algoritmos de clustering en dominios con características musicales reales.

II. Estado del Arte

El presente estado del arte reúne los referentes teóricos y técnicos que sustentan el proyecto de clustering de perfiles musicales sobre el *Top 50 mundial* de Spotify. Se organiza en tres ejes: las herramientas y librerías utilizadas, los algoritmos de clustering considerados, y las metodologías de trabajo adoptadas.

II-A. *Referentes técnicos (herramientas y librerías)*

El ecosistema de Python constituye el estándar de facto en proyectos de Ciencia de Datos debido a su amplia comunidad, su legibilidad y la madurez de sus librerías especializadas [1]. Frente a alternativas como R —orientada principalmente al análisis estadístico y la visualización académica— Python ofrece mayor flexibilidad para integrar preprocesamiento, modelado y visualización dentro de un mismo flujo de trabajo, razón por la cual fue seleccionado como lenguaje principal del proyecto.

Las librerías empleadas se agrupan en tres categorías:

- **Manipulación y análisis de datos:** `Pandas` [2] para la carga, limpieza y transformación del dataset de Spotify; `NumPy` [3] para operaciones vectoriales y cálculo numérico eficiente, incluyendo la transformación logarítmica `np.log1p()` aplicada durante el preprocesamiento.
- **Modelado y evaluación:** `Scikit-learn` [4] provee las implementaciones de K-Means y DBSCAN, la clase `StandardScaler` para el escalado de variables, y métricas de evaluación como el coeficiente de Silhouette y el índice de Davies-Bouldin. El objeto `StandardScaler` entrenado se serializa mediante `joblib` para permitir su reutilización sobre nuevos datos.
- **Visualización:** `Matplotlib` [5] y `Seaborn` [6] se utilizan para generar histogramas, boxplots, mapas de calor de correlación y diagramas de dispersión que facilitan la interpretación de los clusters resultantes.

El entorno de desarrollo elegido son los **Jupyter Notebooks** ejecutados tanto en local como en **Google Colab**, lo que facilita la colaboración entre los integrantes del equipo, la documentación paso a paso de cada decisión metodológica y el acceso a recursos de cómputo sin configuración local adicional.

II-B. *Referentes algorítmicos (métodos y modelos)*

II-B1. Análisis exploratorio y descriptivo: El análisis exploratorio de datos (EDA) es una fase previa indispensable antes de aplicar cualquier algoritmo de clustering [7]. Permite comprender la distribución de cada variable, detectar colinealidades entre features acústicas mediante matrices de correlación de Pearson, e identificar variables con alta asimetría que requieran transformación antes del modelado. Herramientas como histogramas, diagramas de caja (*boxplots*) y mapas de calor de correlación son fundamentales en esta etapa.

II-B2. Preprocesamiento y curación de datos: Una correcta selección y limpieza de variables es determinante para la calidad del clustering [7]. En proyectos de este tipo, es habitual excluir variables contextuales o de popularidad en favor de aquellas que describen propiedades sonoras intrínsecas. Asimismo, variables con distribuciones fuertemente asimétricas suelen requerir una transformación logarítmica para reducir el peso de valores extremos sin descartar información [1].

II-B3. Muestreo y escalado: Cuando el volumen de datos supera los límites de memoria o tiempo de cómputo razonables, el muestreo aleatorio es una estrategia ampliamente aceptada en proyectos de minería de datos [7], siempre que la muestra conserve las propiedades estadísticas del conjunto original. Adicionalmente, dado que los algoritmos de clustering basados en distancias son sensibles a la escala de las variables, la estandarización mediante `StandardScaler` —que transforma cada variable a media cero y desviación estándar unitaria— es un paso previo obligatorio [4]. Serializar el objeto `StandardScaler` entrenado permite reproducir el mismo escalado sobre nuevos datos en el futuro.

II-B4. Algoritmos de clustering: Se evalúan dos algoritmos de clustering no supervisado:

1. **K-Means** [8]: algoritmo de particionamiento que minimiza la inercia intra-cluster. Su principal ventaja es la eficiencia computacional sobre grandes volúmenes de datos; su limitación es la suposición de clusters convexos de tamaño similar. Para determinar el número óptimo de clusters k se utilizarán el método del codo (*Elbow Method*) y el análisis de Silhouette.
2. **DBSCAN** (*Density-Based Spatial Clustering of Applications with Noise*) [9]: agrupa puntos por densidad de vecindad, definida por los parámetros ε (radio de búsqueda) y `min_samples`. Su fortaleza reside en la capacidad de detectar clusters de forma arbitraria y de identificar canciones atípicas que no encajan en ningún perfil musical.

II-B5. Métricas de evaluación: La comparación entre algoritmos se realizará mediante el **coeficiente de Silhouette** [10], que mide la cohesión intra-cluster y la separación inter-cluster en un rango de $[-1, 1]$, donde valores cercanos a 1 indican clusters bien definidos. Como métrica complementaria se empleará el **índice de Davies-Bouldin** [11], donde valores menores reflejan mejor separación entre grupos.

II-C. Referentes procesuales (metodologías de trabajo)

El proyecto sigue el marco de trabajo **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*) [12], ampliamente adoptado en proyectos de minería de datos y analítica de negocios. Sus fases —comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue— se alinean directamente con la estructura del presente informe: introducción, estado del arte, metodología, resultados y conclusiones.

En el contexto específico del análisis musical, trabajos previos como el de Schedl et al. [13] han demostrado que las características acústicas de audio —incluidas las proporcionadas por la API de Spotify— son predictores significativos del comportamiento de los oyentes y la popularidad de las canciones. Del mismo modo, estudios como el de Kim et al. [14] han aplicado técnicas de clustering sobre datos de plataformas de streaming para descubrir taxonomías de géneros musicales, validando la pertinencia del enfoque no supervisado para este tipo de datos.

El flujo de trabajo del equipo sigue prácticas de **reproducibilidad**: el código se versiona en un repositorio de GitHub, los notebooks documentan cada decisión de preprocesamiento y modelado con sus salidas registradas, y los resultados se presentan acompañados de sus métricas de evaluación para garantizar la transparencia del proceso analítico.

III. Área de Aplicación

III-A. Contexto del dominio

La industria del streaming musical ha experimentado un crecimiento exponencial en la última década. Plataformas como Spotify, Apple Music y Amazon Music han transformado la forma en que los consumidores acceden a la música. Actualmente, Spotify cuenta con cientos de millones de usuarios activos mensuales y alberga más de 100 millones de canciones en su catálogo.

Las listas de reproducción generadas algorítmicamente, como Discover Weekly o las listas Top 50 de cada país, constituyen el principal punto de contacto entre la plataforma y el usuario. Detrás de estas recomendaciones existen modelos de aprendizaje automático que analizan las características acústicas de las canciones.

Comprender qué perfiles acústicos predominan entre los grandes éxitos tiene implicaciones directas para la industria: permite optimizar algoritmos de recomendación, orientar decisiones de inversión de discográficas y guiar a artistas independientes sobre qué características potenciar en sus lanzamientos.

III-B. Dataset seleccionado

El dataset utilizado en este proyecto se denomina *Top Spotify Songs in 73 Countries (Daily Updated)* [15], obtenido de la plataforma Kaggle. Contiene las canciones que han aparecido en las listas Top 50 mundial.

III-C. Aporte alternativo (diferenciación)

A continuación, se detallan las diferencias entre el presente trabajo y los análisis públicos existentes en Kaggle:

Primera diferencia: enfoque del problema. La mayoría de los cuadernos disponibles se centran en tareas de regresión o en análisis exploratorio. El presente trabajo aborda un problema de clustering no supervisado.

Segunda diferencia: comparación de múltiples algoritmos. Mientras que los trabajos existentes utilizan únicamente K-Means, este proyecto implementa y compara dos algoritmos: K-Means y DBSCAN.

Tercera diferencia: nomenclatura interpretable. Este trabajo asigna nombres descriptivos a los clusters, facilitando la comunicación a audiencias no técnicas.

Cuarta diferencia: análisis de contenido explícito. Se analiza posteriormente si las canciones con contenido explícito se concentran en determinados clusters, sin utilizarlo como variable de entrada del modelo.

Quinta diferencia: caracterización accionable. El proyecto entrega una caracterización acústica detallada para cada perfil musical identificado.

IV. Metodología

IV-A. Adquisición del conjunto de datos

El conjunto de datos empleado en este estudio, titulado *Top Spotify Songs in 73 Countries (Daily Updated)* y publicado por el usuario Asaniczka en la plataforma Kaggle [15], fue integrado mediante un proceso automatizado. Se implementó una rutina en Python que verifica la existencia de una copia local del archivo; en caso de no estar disponible, se procede a su descarga a través de la API oficial de Kaggle empleando la librería `kagglehub`.

El archivo original posee un tamaño de 474 megabytes y se encuentra en formato CSV. La carga en memoria se realizó mediante la función `read_csv` de la librería `pandas`. El conjunto de datos está compuesto por 2.110.316 registros y 25 atributos. Entre los atributos disponibles se encuentran identificadores (`spotify_id`, `name`, `artists`), variables temporales (`snapshot_date`), métricas de popularidad (`popularity`) y propiedades acústicas como `danceability`, `energy`, `valence`, `tempo` y `loudness`, entre otras.

Esta caracterización inicial constituye la base para las fases subsiguientes de selección de variables y preprocesamiento.

IV-B. Preprocesamiento y curación de datos

El preprocesamiento se inició con la selección de las variables relevantes para el análisis. Se eligieron once atributos acústicos que describen las propiedades musicales de cada canción: `danceability`, `energy`, `valence`, `acousticness`, `instrumentalness`, `liveness`, `speechiness`, `tempo`, `loudness`, `duration_ms` y `mode`. La variable `is_explicit` se reservó para un análisis posterior sobre la distribución del contenido explícito entre los clusters.

A continuación, se aplicaron las siguientes operaciones de limpieza:

- **Valores nulos:** No se detectaron valores ausentes en las once variables seleccionadas.
- **Duplicados:** No se encontraron filas completamente duplicadas en el conjunto de datos.
- **Valores inválidos:** Se eliminaron 30 registros que presentaban valores anómalos: aquellos con `tempo` igual a cero, `duration_ms` no positivo, `mode` diferente de 0 o 1, o valores fuera del rango [0,1] en las variables de proporción.

Para mitigar el efecto de la alta asimetría en la distribución de tres variables (`instrumentalness`, `speechiness` y `liveness`), se aplicó una transformación logarítmica de la forma $\log(x + 1)$. Esta transformación reduce el impacto de valores extremos y aproxima la distribución a una forma más cercana a la normal.

Una vez aplicadas estas transformaciones, el conjunto de datos limpio (2.110.286 registros con las 11 variables acústicas) fue exportado como `spotify_features_clean.csv` para su uso en las etapas posteriores.

IV-C. Análisis exploratorio de datos

Se realizó un análisis exploratorio sobre el conjunto de datos limpio para comprender la estructura y las relaciones entre las once variables acústicas seleccionadas.

IV-C1. Estadísticos descriptivos: La Tabla I presenta los estadísticos principales de cada variable. Los resultados muestran escalas muy diferentes entre variables, lo que confirma la necesidad de estandarización previa al clustering. La Figura 1 muestra la distribución de cada variable, donde se observa visualmente la alta asimetría en variables como `instrumentalness` y `speechiness`.

Cuadro I
ESTADÍSTICOS DESCRIPTIVOS DE LAS VARIABLES ACÚSTICAS

Variable	Media	Mediana	Rango
danceability	0.676	0.700	[0.066, 0.988]
energy	0.649	0.668	[0.000, 0.998]
valence	0.546	0.548	[0.000, 0.992]
acousticness	0.275	0.191	[0.000, 0.996]
instrumentalness	0.019	0.000	[0.000, 0.691]
liveness	0.153	0.115	[0.014, 0.685]
speechiness	0.088	0.057	[0.022, 0.671]
tempo (BPM)	122.101	119.965	[36.6, 236.1]
loudness (dB)	-6.773	-6.064	[-54.3, 3.2]
duration (ms)	194312	186191	[16320, 1296000]
mode	0.537	1.000	[0, 1]

IV-C2. Análisis de correlaciones y asimetría: Se generó una matriz de correlación de Pearson (Figura 2). La correlación más relevante fue entre `energy` y `loudness` (0.653). No se identificaron correlaciones superiores a 0.7, por lo que no fue necesario eliminar variables por redundancia.

El análisis de asimetría reveló que `instrumentalness` (5.79), `speechiness` (1.96), `liveness` (1.91), `loudness` (-4.46) y `duration_ms` (1.85) presentan

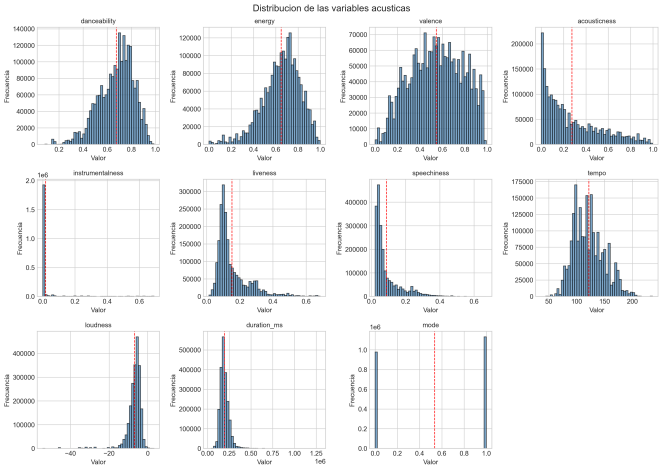

Figura 1. Distribución de las variables acústicas

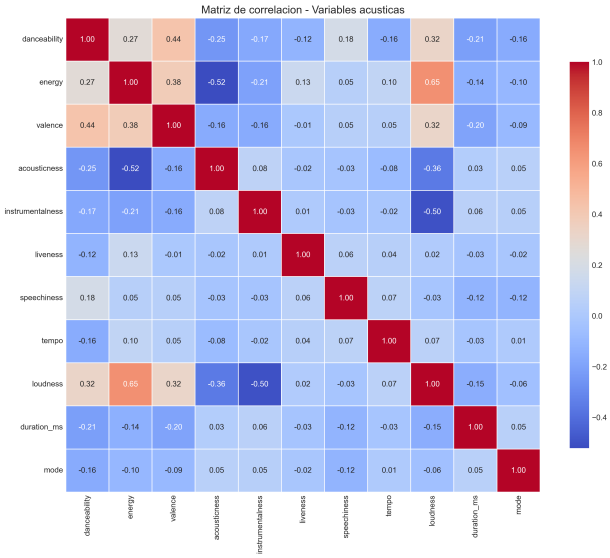

Figura 2. Matriz de correlación de Pearson entre variables acústicas

alta asimetría, lo que justifica la transformación logarítmica aplicada en el preprocesamiento. La detección de outliers se complementa con los diagramas de caja (boxplots) presentados en la Figura 3.

IV-C3. Análisis de modo: El 53.6 % de las canciones están en modo mayor y el 46.4 % en modo menor. Esta distribución se utilizará para caracterizar los clusters encontrados.

IV-D. Preparación final para clustering

Previo a la aplicación de los algoritmos de clustering, se realizaron dos operaciones adicionales sobre el conjunto de datos limpio:

IV-D1. Muestreo: Debido a las limitaciones de memoria RAM del entorno de trabajo y al alto costo computacional de algunos algoritmos (notablemente DBSCAN), se optó por trabajar con una muestra aleatoria simple de 100.000 registros del conjunto de datos limpio. Esta muestra conserva las

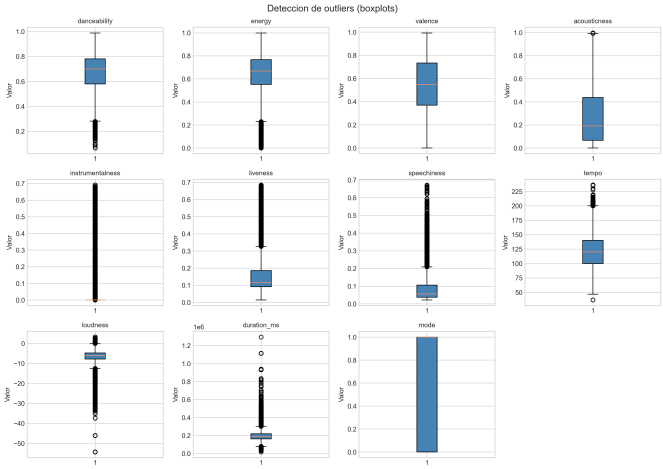

Figura 3. Diagramas de caja para detección de outliers

propiedades estadísticas del conjunto original y permite la ejecución eficiente de los algoritmos.

IV-D2. Estandarización: Dado que los algoritmos de clustering basados en distancias son sensibles a la escala de las variables, se aplicó una estandarización mediante `StandardScaler` de la librería `scikit-learn`. Este proceso transforma cada variable para que tenga media cero y desviación estándar uno, evitando que las diferencias de escala influyan en el cálculo de distancias entre puntos. El objeto `StandardScaler` entrenado se serializó con `joblib` para permitir su reutilización sobre nuevos datos.

El resultado de esta etapa fue el archivo `spotify_muestra_100k_scaled.csv`, que contiene 100.000 registros con las 11 variables estandarizadas, listo para ser utilizado en la fase de modelado.

IV-E. Modelado predictivo (clustering no supervisado)

Para abordar el problema de segmentación de canciones por sus propiedades acústicas, se seleccionaron dos algoritmos de clustering no supervisado: K-Means y DBSCAN. Ambos algoritmos se ejecutaron sobre la misma muestra previamente preparada de 100.000 canciones estandarizadas, contenida en el archivo `spotify_muestra_100k_scaled.csv` generado en la etapa anterior. La comparación entre algoritmos permite evaluar cuál produce una mejor separación de los datos.

IV-E1. K-Means: El algoritmo K-Means agrupa los datos buscando minimizar la suma de distancias cuadradas entre cada punto y el centroide de su cluster, mediante la siguiente función objetivo:

$$J = \sum_{j=1}^{k} \sum_{i=1}^{n} \|x_i - \mu_j\|^2 \tag{1}$$

donde x_i representa cada canción descrita por sus características acústicas, μ_j es el centroide del cluster j y k es el número de clusters.

La implementación se realizó con la librería `scikit-learn` sobre la muestra de 100.000 canciones estandarizadas. Para determinar el número óptimo de clusters, se evaluaron valores de k entre 2 y 10 utilizando dos criterios:

- **Método del codo:** Se analizó la inercia (suma de distancias cuadradas intra-cluster) para cada valor de k, observando el punto donde la disminución de la inercia se vuelve marginal.
- **Coeficiente de Silhouette:** Se calculó el coeficiente de Silhouette para cada k, seleccionando el valor que maximiza esta métrica.

El modelo final se configuró con los parámetros `n_init = 10` y `random_state = 42` para garantizar la reproducibilidad de los resultados.

IV-E2. DBSCAN: El algoritmo DBSCAN (Density-Based Spatial Clustering of Applications with Noise) agrupa puntos basándose en la densidad de vecinos. A diferencia de K-Means, no requiere especificar el número de clusters a priori y permite identificar puntos atípicos que no pertenecen a ningún grupo.

IV-E2a. Reducción de dimensionalidad.: Previo a la aplicación de DBSCAN, se aplicó Análisis de Componentes Principales (PCA) sobre los datos estandarizados para reducir las 11 dimensiones originales a 3 componentes, conservando aproximadamente el 48 % de la varianza total. Esto mejora la eficiencia computacional del algoritmo (cuya complejidad es $O(n^2)$ en el peor caso) sin perder la estructura principal de los datos.

IV-E2b. Selección de hiperparámetros.: El parámetro `eps` (radio de vecindad) se determinó mediante el método de la gráfica k-distance, que ordena las distancias al quinto vecino más cercano de cada punto. El valor seleccionado fue `eps = 1.1`, correspondiente al punto de inflexión (codo) de la curva. El parámetro `min_samples` se fijó en 5, estableciendo el número mínimo de puntos requerido para formar una región densa.

IV-E2c. Implementación.: La implementación se realizó con la librería `scikit-learn`, utilizando el algoritmo `ball_tree` para optimizar la búsqueda de vecinos.

IV-E3. Métricas de evaluación: La comparación entre algoritmos se realizará mediante el **coeficiente de Silhouette** [10], que mide la cohesión intra-cluster y la separación inter-cluster en un rango de $[-1, 1]$, donde valores cercanos a 1 indican clusters bien definidos. Como métrica complementaria se empleará el **índice de Davies-Bouldin** [11], donde valores menores reflejan mejor separación entre grupos.

V. Resultados

A continuación, se presentan los resultados obtenidos tras la aplicación de los algoritmos de clustering no supervisado sobre el conjunto de datos de Spotify. Para cada algoritmo, se reportan las métricas de evaluación y la caracterización de los clusters encontrados.

V-A. K-Means

El algoritmo K-Means se ejecutó sobre una muestra de 100.000 canciones previamente estandarizadas.

V-A1. Determinación del número óptimo de clusters: Para determinar el valor óptimo de k, se evaluaron valores entre 2 y 10 utilizando dos criterios complementarios: el método del codo (basado en la inercia) y el coeficiente de Silhouette.

El método del codo mostró una disminución significativa de la inercia hasta $k = 4$, a partir del cual la mejora se vuelve marginal. Por su parte, el coeficiente de Silhouette alcanzó su valor máximo en $k = 2$, con un valor de 0.2096. Considerando ambos criterios y la interpretabilidad de los resultados, se seleccionó $k = 2$ como número óptimo de clusters.

V-A2. Métricas de evaluación: La Tabla II presenta las métricas obtenidas para el modelo K-Means con $k = 2$. El coeficiente de Silhouette de 0.2096 indica una estructura de clusters aceptable, aunque con cierta superposición entre grupos. El índice de Davies-Bouldin (1.9563) y el índice de Calinski-Harabasz (782.36) complementan la evaluación.

Cuadro II
MÉTRICAS DE EVALUACIÓN - K-MEANS

Métrica	Valor
Número de clusters (k)	2
Coeficiente de Silhouette	0.2096
Índice de Davies-Bouldin	1.9563
Índice de Calinski-Harabasz	782.36
Tiempo de ejecución	3.16 segundos

V-A3. Clusters encontrados: K-Means identificó 2 clusters, sin puntos de ruido (todos los datos son asignados a algún grupo). La Tabla III presenta los valores promedio de las variables acústicas para cada cluster.

Cuadro III
VALORES PROMEDIO POR CLUSTER - K-MEANS

Variable	Cluster 0	Cluster 1
Danceability	0.592	0.699
Energy	0.491	0.743
Valence	0.382	0.611
Acousticness	0.482	0.172
Instrumentalness	0.045	0.010
Liveness	0.160	0.191
Speechiness	0.095	0.111
Tempo (BPM)	119.03	124.61
Loudness (dB)	-9.189	-5.726
Duration (ms)	-	-
Mode	-	-

V-A4. Interpretación de los clusters: A partir de los valores promedio presentados, se asignaron nombres descriptivos a cada cluster:

- **Cluster 1 (Bailable, energética y positiva):** Alta bailabilidad (0.699), alta energía (0.743) y positividad alta (0.611). Corresponde al perfil típico de canciones alegres, enérgicas y orientadas al baile.
- **Cluster 0 (Mixta / equilibrada):** Valores moderados en todas las dimensiones, con menor energía (0.491) y menor positividad (0.382). Representa un perfil musical más sobrio, con mayor acusticidad (0.482) y volumen más bajo.

V-B. DBSCAN

El algoritmo DBSCAN se ejecutó sobre una muestra de 100.000 canciones previamente estandarizadas. Los parámetros utilizados fueron `eps = 1.1` y `min_samples = 5`, seleccionados mediante el método de la gráfica k-distance.

V-B1. Métricas de evaluación: La Tabla IV presenta las métricas utilizadas para evaluar la calidad del clustering. El coeficiente de Silhouette alcanzó un valor de 0.516, lo que indica una estructura de clusters buena, con puntos bien ubicados dentro de sus grupos y razonablemente separados de los demás. El índice de Davies-Bouldin (1.160) se sitúa en el rango aceptable, confirmando que los clusters mantienen una separación adecuada. El índice de Calinski-Harabasz (1370.36) corrobora una buena cohesión interna y separación global entre los grupos.

Cuadro IV
MÉTRICAS DE EVALUACIÓN - DBSCAN

Métrica	Valor
Coeficiente de Silhouette	0.516
Índice de Davies-Bouldin	1.160
Índice de Calinski-Harabasz	1370.36

V-B2. Clusters encontrados: DBSCAN identificó un total de **8 clusters** y **12 puntos de ruido** (canciones atípicas que no fueron asignadas a ningún grupo). El cluster de mayor tamaño (cluster 0) concentra 99.377 canciones, equivalente al 99.4 % de la muestra. Los Cuadros V y VI resumen los valores promedio de las variables acústicas para cada uno de los 8 clusters encontrados.

Cuadro V
VALORES PROMEDIO POR CLUSTER - DBSCAN (PARTE 1)

Cluster	Danceability	Energy	Valence	Tamaño
0	0.678	0.652	0.549	99,377
1	0.145	0.393	0.062	295
2	0.168	0.003	0.219	152
3	0.094	0.002	0.068	16
4	0.458	0.297	0.357	90
5	0.531	0.038	0.800	7
6	0.270	0.277	0.082	36
7	0.418	0.106	0.800	15

Cuadro VI
VALORES PROMEDIO POR CLUSTER - DBSCAN (PARTE 2)

Cluster	Acousticness	Instrumentalness	Tamaño
0	0.274	0.016	99,377
1	0.583	0.537	295
2	0.192	0.582	152
3	0.247	0.000	16
4	0.866	0.284	90
5	0.894	0.019	7
6	0.018	0.395	36
7	0.994	0.029	15

V-B3. Interpretación de los clusters: A partir de los valores promedio presentados, se asignaron nombres descriptivos a cada cluster:

- **Cluster 0 (Popular comercial):** Alta bailabilidad (0.678), energía media-alta (0.652) y positividad media (0.549). Corresponde al perfil típico de los grandes éxitos en plataformas de streaming.
- **Cluster 1 (Instrumental introspectivo):** Baja bailabilidad (0.145), baja positividad (0.062) y alta instrumentalidad (0.537). Representa composiciones instrumentales de carácter emocional.
- **Cluster 2 (Ambiental extremo):** Energía prácticamente nula (0.003) y volumen extremadamente bajo. Música de fondo o ambiental.
- **Cluster 3 (Balada lenta):** Energía casi inexistente (0.002) y positividad muy baja (0.068). Baladas nostálgicas o tristes.
- **Cluster 4 (Rap hablado):** Alto contenido de voz hablada (speechiness: 0.470) y alta acusticidad (0.866). Predominio de voz sobre melodía.
- **Cluster 5 (Folk alegre):** Positividad muy alta (0.800), energía muy baja (0.038) y alta acusticidad (0.894). Música alegre pero relajada, de carácter acústico.
- **Cluster 6 (Estudio y concentración):** Carácter instrumental (0.395), energía controlada (0.277). Música de fondo para tareas de concentración.
- **Cluster 7 (Infantil y lullabies):** Positividad muy alta (0.800) y acusticidad casi total (0.994). Similar a canciones de cuna o música infantil.

V-C. Comparativa entre algoritmos

La Tabla VII resume los resultados obtenidos por ambos algoritmos. DBSCAN supera a K-Means en el coeficiente de Silhouette (0.516 vs 0.210), lo que indica una mejor definición de los clusters. Sin embargo, K-Means es significativamente más rápido (3.16 segundos vs tiempo no comparable por las diferencias en preprocesamiento) y produce una segmentación más simple de interpretar.

Cuadro VII
COMPARATIVA DE ALGORITMOS

Métrica	K-Means	DBSCAN
Número de clusters	2	8
Coeficiente de Silhouette	0.210	0.516
Índice de Davies-Bouldin	1.956	1.160
Porcentaje de ruido	0 %	0.012 %
Tiempo de ejecución (seg)	3.16	—

VI. CONCLUSIONES

VI-A. Respuesta a las preguntas de investigación

A continuación, se responden las preguntas de investigación planteadas en la introducción, con base en los resultados obtenidos.

Pregunta 1: ¿Cuántos grupos naturales de canciones existen en el Top 50 mundial de Spotify?

Los resultados de ambos algoritmos muestran que la música popular mundial no es homogénea. El algoritmo K-Means identificó 2 grupos naturales, mientras que DBSCAN identificó 8 grupos más 12 puntos de ruido. La diferencia se debe a la naturaleza de cada algoritmo: K-Means tiende a agrupar los datos en pocos clusters de gran tamaño, mientras que DBSCAN, al ser basado en densidad, es capaz de detectar clusters más pequeños y específicos. Considerando ambos enfoques, se puede concluir que existen al menos 2 grandes perfiles musicales dominantes en el Top 50, con múltiples subperfiles de nicho.

Pregunta 2: ¿Es posible asignar nombres descriptivos a los clusters basándose en sus valores promedio de danceability, energy y valence?

Sí, es posible. Utilizando exclusivamente las variables danceability, energy y valence, se distinguen claramente los diferentes perfiles musicales. Para K-Means se identificaron dos perfiles: «Bailable, energética y positiva» (alta danceability, alta energy, alta valence) y «Mixta / equilibrada» (valores moderados en todas las dimensiones). Para DBSCAN se identificaron perfiles como «Popular comercial», «Instrumental introspectivo», «Ambiental extremo», «Balada lenta», «Rap hablado», «Folk alegre», «Estudio y concentración» e «Infantil y lullabies».

Pregunta 3: ¿Qué combinación de valores caracteriza a cada perfil musical?

Las combinaciones características para K-Means son:

- **Cluster 1 (Bailable, energética y positiva):** danceability 0.699, energy 0.743, valence 0.611.
- **Cluster 0 (Mixta / equilibrada):** danceability 0.592, energy 0.491, valence 0.382.

Para DBSCAN, las combinaciones más representativas son:

- **Popular comercial:** danceability 0.678, energy 0.652, valence 0.549.
- **Folk alegre:** danceability 0.531, energy 0.038, valence 0.800.
- **Balada lenta:** danceability 0.094, energy 0.002, valence 0.068.

Pregunta 4: ¿Qué algoritmo de clustering produce los mejores resultados en términos de coeficiente de Silhouette?

El algoritmo DBSCAN obtuvo un coeficiente de Silhouette de 0.516, superior al de K-Means (0.210). Esto indica que DBSCAN produce clusters mejor definidos y más separados entre sí. Sin embargo, K-Means tiene la ventaja de no generar puntos de ruido (0 % de datos no asignados) y ser más simple de interpretar. La elección del algoritmo depende del objetivo: DBSCAN es preferible si se busca identificar clusters de nicho y detectar datos atípicos, mientras que K-Means es más adecuado para una segmentación rápida y general del mercado musical.

VI-B. Aportes y hallazgos principales

Los principales aportes de este trabajo son los siguientes:

1. Se ha demostrado que es posible segmentar los grandes éxitos de Spotify en perfiles acústicos diferenciados,

identificando al menos 2 grandes grupos y múltiples subgrupos de nicho.
2. Se ha propuesto un sistema de nomenclatura semántica para los clusters (Bailable, energética y positiva; Popular comercial; Folk alegre; Instrumental introspectivo, etc.), facilitando la comunicación de resultados a audiencias no técnicas.
3. Se ha establecido una comparativa cuantitativa entre K-Means y DBSCAN, evidenciando que DBSCAN ofrece mejor separación de clusters (Silhouette 0.516 vs 0.210), mientras que K-Means es más rápido de ejecutar y más simple de interpretar.
4. Se han formulado caracterizaciones acústicas para la industria musical, especificando qué combinaciones de danceability, energy y valence caracterizan a cada perfil de éxito.
5. Se ha diferenciado explícitamente este trabajo de análisis públicos existentes en Kaggle, destacando el enfoque en clustering no supervisado, la comparación de dos algoritmos (K-Means y DBSCAN) y la asignación de nombres interpretables a los clusters.

VI-C. Limitaciones y trabajo futuro

Limitaciones del estudio:

- El análisis se limita a canciones que ya alcanzaron el Top 50, introduciendo un sesgo de selección. No se analizan canciones que no lograron éxito.
- El coeficiente de Silhouette de DBSCAN (0.516) indica una calidad de clustering buena pero no excelente. Existe cierta superposición entre clusters.
- El muestreo a 100.000 canciones, aunque necesario por costo computacional, podría haber excluido algunos patrones presentes en el dataset completo de 2.1 millones de registros.
- No se incluyeron variables contextuales como género musical, año de lanzamiento o país de origen, que podrían enriquecer la segmentación.

Trabajo futuro:

- Aplicar técnicas de reducción de dimensionalidad alternativas (t-SNE, UMAP) para visualizar mejor la separación entre clusters.
- Incorporar variables temporales para analizar cómo evolucionan los perfiles acústicos de los éxitos a lo largo del tiempo.
- Entrenar un clasificador supervisado que, dadas las características acústicas de una canción nueva, prediga su perfil cluster.
- Repetir el análisis por país o región para identificar diferencias culturales en los perfiles de éxito musical.

VI-D. Aprendizajes del proceso

La realización de este proyecto ha permitido consolidar aprendizajes fundamentales en el ciclo de vida de un proyecto de Ciencia de Datos:

- **Importancia del preprocesamiento:** Se confirmó que el preprocesamiento y la limpieza de datos consumen una parte significativa del tiempo del proyecto, siendo una fase crítica para obtener resultados confiables.
- **No hay algoritmo universalmente mejor:** La elección del algoritmo de clustering depende del objetivo del análisis (segmentación general vs. detección de nichos) y de las características del dataset.
- **Valor de la interpretabilidad:** La asignación de nombres descriptivos a los clusters es tan importante como los resultados numéricos, especialmente para comunicar hallazgos a audiencias no técnicas.
- **Trabajo colaborativo:** Se confirmó la importancia del trabajo en equipo con control de versiones (GitHub) y de una estructura modular del proyecto (datos, notebooks, documentación) para facilitar la integración de contribuciones individuales.
- **Iteración constante:** El proceso de análisis de datos es inherentemente iterativo; los resultados iniciales guían nuevas preguntas y refinamientos del modelo.

REFERENCIAS

[1] J. VanderPlas, *Python Data Science Handbook: Essential Tools for Working with Data*. Sebastopol, CA: O'Reilly Media, 2016.

[2] W. McKinney, "Data structures for statistical computing in python," in *Proceedings of the 9th Python in Science Conference*, S. van der Walt and J. Millman, Eds., 2010, pp. 56–61.

[3] C. R. Harris *et al.*, "Array programming with NumPy," *Nature*, vol. 585, pp. 357–362, 2020.

[4] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[5] J. D. Hunter, "Matplotlib: A 2d graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.

[6] M. L. Waskom, "seaborn: statistical data visualization," *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021.

[7] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Waltham, MA: Morgan Kaufmann, 2011.

[8] J. B. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1. University of California Press, 1967, pp. 281–297.

[9] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*. AAAI Press, 1996, pp. 226–231.

[10] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.

[11] D. L. Davies and D. W. Bouldin, "A cluster separation measure," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-1, no. 2, pp. 224–227, 1979.

[12] R. Wirth and J. Hipp, "CRISP-DM: Towards a standard process model for data mining," in *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 2000, pp. 29–39.

[13] M. Schedl, H. Zamani, C.-W. Chen, Y. Deldjoo, and M. Elahi, "Current challenges and visions in music recommender systems research," *International Journal of Multimedia Information Retrieval*, vol. 7, no. 2, pp. 95–116, 2018.

[14] J. Kim, J. Urbano, C. C. S. Liem, and A. Hanjalic, "One deep music representation to rule them all? a comparative analysis of different representation learning strategies," in *Neural Computing and Applications*, vol. 32, 2020, pp. 1067–1093.

[15] Asaniczka, "Top spotify songs in 73 countries (daily updated)," Kaggle, 2025, consultado en abril de 2026. [Online]. Available: https://www.kaggle.com/datasets/asaniczka/top-spotify-songs-in-73-countries-daily-updated/data